

NO-HALU MODEL

Schema 1 — Systeemarchitectuur


2026

Inleiding

Definitie: 'No-Halu' staat voor 'Low Hallucination'. Het model reduceert hallucinaties maximaal, maar kan deze nooit volledig uitsluiten. Menselijke verificatie blijft vereist bij kritische toepassingen.

De systeemarchitectuur van het No-Halu Model (NHM) beschrijft de structurele opbouw van het triple-agent consensussysteem. Het schema toont de relaties tussen de centrale Orchestrator, de drie onafhankelijke AI-agents, de Scoring Engine, het kruisverificatiemechanisme, de Harmonizer en de einduitkomst.

Schema: Systeemarchitectuur



Schema 1 — Systeemarchitectuur van het No-Halu Model. Zwarte 1pt lijntekening. © 2026

Toelichting op de componenten

Orchestrator

De Orchestrator is de centrale controller van het systeem. Hij is verantwoordelijk voor het initialiseren van de agentcycli, het aggregeren van scores, het bewaken van de convergentieconditie en het activeren van de halt-logica wanneer de divergentie onder de drempelwaarde epsilon daalt. Zonder de Orchestrator kunnen de drie agents niet gecoördineerd opereren.

Agent Pool (A1, A2, A3)

De drie agents zijn functioneel identiek maar operationeel volledig geïsoleerd. Elk agent beschikt over een eigen context-venster zonder toegang tot de context van de andere agents. De licht variërende temperatuurparameters (0.65 / 0.70 / 0.75) zorgen voor output-diversificatie, wat de kans vergroot dat tenminste één agent een correcte, goed onderbouwde respons genereert.

- Agent 1: lage temperatuur — meer deterministisch, hogere consistentie.
- Agent 2: middelhoge temperatuur — balans tussen creativiteit en precisie.
- Agent 3: hogere temperatuur — meer exploratief, groter divergentiebereik.

Scoring Engine

Na ontvangst van de drie agentresponsen berekent de Scoring Engine voor elke respons een vertrouwensscore $S(R)$ op vier dimensies: interne consistentie (C), factual density (F), semantische coherentie (Coh) en bronverankering (Src). De winnende agent A^* is de agent met de hoogste totaalscore: $A^* = \operatorname{argmax}(S)$.

Kruisverificatie

De twee verliezende agents challengen de winnaar via een adversariale verificatiequery. Voor elke challengers agent wordt een weerleggingsscore W berekend als de cosinus-afstand tussen de embeddings van de challengerrespons en de winnaarsrespons. Een hoge W -score indiceert significante divergentie.

Harmonizer

De Harmonizer integreert de beste componenten uit alle drie responsen. Hij extraheert consensus-zinnen — zinnen die in ten minste twee van de drie agentresponsen inhoudelijk overeenkomen — en bouwt hieruit een geconsolideerde respons op. Dit proces vermindert de invloed van individuele agentfouten.

Terugkoppeling en convergentie

Wanneer de maximale divergentie $D(n)$ na de harmonisatieronde nog steeds boven de drempelwaarde epsilon ligt, start een nieuwe iteratiecyclus. Dit proces herhaalt zich totdat convergentie bereikt is of het maximale iteratieaantal overschreden wordt. Het pijldiagram links in het schema illustreert deze terugkoppellus.

Uitkomst

De finale uitkomst is de geharmoniseerde respons na convergentie. Samen met de respons worden metadata meegeleverd: de finale confidence-score, het aantal doorlopen iteraties, de divergentie-trace per iteratie en de verwerkingstijd in milliseconden.

Architectuurkenmerken

- Parallele verwerking: de drie agentaanroepen worden gelijktijdig uitgevoerd (async I/O).
- Fout-tolerantie: het systeem continueert ook bij uitval van één agent (fallback naar twee).

- Schaalbaarheid: de Orchestrator ondersteunt uitbreiding naar meer dan drie agents.
- Caching: tussenliggende responsen worden gecacht om herberekening te vermijden.
- Audittrail: alle iteratiestappen worden gelogd voor traceerbaarheid en GDPR-compliance.