

NO-HALU MODEL

Schema 3 — Procesflow


2026

Inleiding

Definitie: 'No-Halu' staat voor 'Low Hallucination'. De procesflow illustreert hoe het model stap voor stap hallucinaties reduceert. Volledige uitsluiting van hallucinaties blijft theoretisch onmogelijk.

De procesflow van het No-Halu Model beschrijft de opeenvolgende stappen die het systeem doorloopt van het ontvangen van een gebruikersprompt tot het leveren van een geharmoniseerde, betrouwbare eindrespons. Het schema maakt gebruik van flowchartconventies: rechthoeken voor processtappen, een ruit voor de beslissingsconditie.

Schema: Procesflow



Schema 3 — Procesflow van het No-Halu Model. Zwarte 1pt lijntekening. Gestippeld kader = verificatiestap, ruit = beslissing. © 2026

Toelichting per stap

Stap 0 — Preprocessing (~10ms)

De ingekomen prompt wordt gesaniteerd: HTML-tags worden verwijderd, speciale tekens worden genormaliseerd en de lengte wordt gecontroleerd (maximum: 8.192 tokens). Vervolgens wordt het domein gedetecteerd op basis van sleutelwoordanalyse (medisch, juridisch, technisch of algemeen). Op basis van het domein worden de gewichtsvectoren (a, b, g, d) automatisch gekalibreerd.

Stap 1 — Parallele Inferentie (~800ms)

De drie agents ontvangen gelijktijdig de gesaniteerde prompt via asynchrone I/O-aanroepen. Elke agent verwerkt de prompt volledig onafhankelijk, zonder kennis van de responsen van de andere agents. De parallelle uitvoering minimaliseert de totale wachttijd.

Stap 2 — Scoring-Evaluatie (~50ms)

Voor elke ontvangen agentrespons berekent de Scoring Engine een vertrouwensscore $S(R)$. Dit levert drie scores op: $S(R1)$, $S(R2)$ en $S(R3)$. De scores worden opgeslagen samen met de individuele deelscores per dimensie voor auditdoeleinden.

Stap 3 — Winnaar-Selectie (~5ms)

De winnende agent A^* wordt bepaald door de argmax-operatie over de drie scores. In geval van gelijke scores wint de agent met de laagste temperatuur (hogere determinisme). De winner-ID wordt doorgegeven aan de kruisverificatiemodule.

Stap 4 — Kruisverificatie (~600ms)

De twee verliezende agents genereren elk een challenge-respons op de winnende respons. Voor elke challengerrespons wordt de weerleggingsscore W berekend als de cosinus-afstand tussen de embeddings. De maximale W -waarde over beide challengers is de divergentiemaatstaf $D(n)$ voor deze iteratie.

Stap 5 — Harmonisatie (~200ms)

De Harmonizer integreert de beste componenten uit alle drie responsen. Consensus-zinnen — zinnen die inhoudelijk overeenkomen in ten minste twee agentresponsen — krijgen prioriteit. Het resultaat is een geconsolideerde respons R_{harm} .

Stap 6 — Convergentiecheck (~10ms)

De convergentiebeslissing is de enige vertakkingsconditie in het proces. Als $D(n)$ kleiner is dan epsilon (standaard: 0.05), is convergentie bereikt en wordt de uitkomst geretourneerd. Als $D(n)$ groter of gelijk is aan epsilon en het iteratieaantal onder het maximum ligt, start een nieuwe cyclus vanaf stap 1 met de geharmoniseerde respons als startpunt.

Uitkomst

De uitkomst bevat: de geharmoniseerde respons, de finale confidence-score, het aantal doorlopen iteraties, een boolean die aangeeft of convergentie bereikt is, de divergentie-trace als array per iteratie, en de totale verwerkingstijd.

Notities bij het schema

- Rechthoeken met doorgetrokken lijn: reguliere processtappen.
- Rechthoek met gestippelde lijn: verificatiestap (adversariale verwerking).
- Ruit: beslissingsconditie ($D(n) < \epsilon$).
- Terugkoppelpijl links: herstart van de cyclus bij niet-convergentie.
- Schattingen zijn gebaseerd op een standaard cloud-omgeving met LLM-API-aanroepen via internet.