

NO-HALU MODEL

Schema 2 — Scoringsformule S(R)


2026

Inleiding

Definitie: 'No-Halu' staat voor 'Low Hallucination'. Het scoringsmodel kwantificeert de betrouwbaarheid van elke agentrespons. Een hoge score duidt op een lage kans op hallucinatie, maar sluit fouten nooit volledig uit.

Het scoringsmodel is de kern van het No-Halu Model. Het kwantificeert de kwaliteit van elke agentrespons op vier meetbare dimensies en berekent een gewogen totaalscore die dient als basis voor de winnaar-selectie en de harmonisatie. Het schema illustreert de opbouw van de formule en de samenhang tussen de vier dimensies.

Schema: Scoringsformule



Schema 2 — Scoringsformule en convergentieformule van het No-Halu Model. Zwarte 1pt lijntekening. © 2026

Toelichting op de formule

Hoofdformule S(R)

De vertrouwensscore $S(R)$ voor een respons R is gedefinieerd als de gewogen som van vier dimensies:

$$S(R) = a \cdot C(R) + b \cdot F(R) + g \cdot Coh(R) + d \cdot Src(R)$$

De gewichtensom is per definitie gelijk aan 1.0: $a + b + g + d = 1.0$. De standaardwaarden zijn ontworpen om consistentie en factualiteit zwaarder te wegen dan coherentie en bronverankering, omdat eerstgenoemden directer gerelateerd zijn aan het hallucinatierisico.

Dimensie 1: C(R) — Interne Consistentie (gewicht: a = 0.30)

Interne consistentie meet in welke mate de respons intern tegenstrijdig is. Contradictie-indicatoren zoals 'however this contradicts', 'but also states the opposite' verlagen de score. Structureel volledige en coherent opgebouwde responsen scoren hoger. Extreem korte responsen (minder dan 10 woorden) worden gesanctioneerd.

- Bereik: 0.0 (maximaal inconsistent) tot 1.0 (volledig consistent).
- Standaardscore bij ontbreken van contradictie-indicatoren: 1.0.
- Sanctie per gevonden indicator: -0.15.

Dimensie 2: F(R) — Factual Density (gewicht: b = 0.30)

Factual Density kwantificeert de verhouding van verifieerbare claims tot het totale aantal claims in de respons. Zinnen met specifieke nummers, jaren, maten of expliciete bronverwijzingen worden als feitelijk onderbouwd beschouwd. Absolutisme-markers — uitspraken die absolute zekerheid claimen zonder onderbouwing — verlagen de score.

- Bereik: 0.0 tot 1.0.
- Absolutisme-markers ('always', '100% certain', 'guaranteed'): sanctie van -0.10 per gevonden patroon.

Dimensie 3: Coh(R) — Semantische Coherentie (gewicht: g = 0.25)

Semantische coherentie meet de mate van inhoudelijke overlap tussen de respons en de originele prompt. In een productie-implementatie wordt dit berekend via cosinus-similariteit van vectorembeddings: $\text{cosine_sim}(\text{embed}(R), \text{embed}(P))$. In een vereenvoudigde implementatie wordt Jaccard-overeenkomst van sleutelwoorden gebruikt als proxy.

- Bereik: 0.0 tot 1.0.
- Productie-implementatie: cosinus-similariteit via embedding-model (bijv. all-MiniLM-L6-v2).
- Demo-implementatie: keyword-overlap als vereenvoudigde proxy.

Dimensie 4: Src(R) — Bronverankering (gewicht: d = 0.15)

Bronverankering meet de aanwezigheid van grondingsindicatoren: uitdrukkingen die verwijzen naar bewijs, onderzoek of externe bronnen. Responsen die expliciteren dat hun claims op onderzoek gebaseerd zijn, worden als betrouwbaarder beschouwd.

- Voorbeeldindicatoren: 'according to', 'research shows', 'studies indicate', 'peer-reviewed'.
- Baseline-score: 0.20 (bij ontbreken van alle indicatoren).
- Toevoeging per gevonden indicator: +0.13 (tot maximum 1.0).

Convergentieformule

De divergentie $D(n)$ tussen de agentresponsen na n iteraties wordt gemodelleerd door een negatief-exponentieel vervalproces:

$$D(n) = D(0) \cdot e^{(-\lambda n)}$$

Waarbij $D(0)$ de initiële divergentie is, n het iteratienummer en λ de convergentiesnelheid (empirisch: 0.3-0.7 afhankelijk van het probleemdomein). Het systeem stopt wanneer $D(n) < \epsilon$ (standaard: 0.05).

Winnaar-selectie

Na berekening van $S(R)$ voor alle drie agentresponsen wordt de winnende agent A^* bepaald door de argmax-operatie:

$$A^* = \operatorname{argmax}(S(R1), S(R2), S(R3))$$

De winnende agent heeft de hoogste vertrouwensscore. Deze agent wordt vervolgens blootgesteld aan adversariale kruisverificatie door de twee verliezende agents, om de robuustheid van zijn respons te testen.