

NO-HALU MODEL

Schema 4 — Semantisch Ontologie-Model

2026


Inleiding

Definitie: 'No-Halu' staat voor 'Low Hallucination'. Het semantische model beschrijft de informatie-architectuur en klasse-relaties van het systeem. Geen enkel model garandeert volledige afwezigheid van hallucinaties.

Het semantische ontologie-model beschrijft de kernklassen van het No-Halu Model, hun eigenschappen en de relaties daartussen. Het diagram is opgesteld conform UML-klasse-diagramnotatie: klassen zijn weergegeven als rechthoeken met zwarte koptekst, eigenschappen en methoden zijn gespecificeerd per compartiment, relaties zijn weergegeven als lijnen met navigatiepijlen.

Schema: Semantisch Ontologie-Model

NHM Semantisch Ontologie-Model — Schema 4



Schema 4 — Semantisch ontologie-model van het No-Halu Model (UML-klasse-diagram). Zwarte 1pt lijntekening. Doorgetrokken lijn = associatie, gestippeld = afhankelijkheid. © 2026

Toelichting per klasse

Klasse: Orchestrator

De Orchestrator is de centrale beheerklasse. Hij houdt de toestand bij van de volledige NHM-pijplijn per verzoek, beheert het maximale iteratieaantal en de convergentiedrempel, en slaat de divergentie-trace op als float-array voor auditdoeleinden.

- `maxIterations: int` — maximaal toegestane iteraties (standaard: 10).

- `epsilon`: float — convergentiedrempelwaarde (standaard: 0.05).
- `divergenceTrace`: float[] — $D(n)$ per voltooide iteratie.
- `query(prompt)`: NHMResult — start de NHM-pijplijn en retourneert het eindresultaat.

Klasse: Agent

De Agent-klasse representeert een individuele AI-agent in de pool. Elke instantie heeft een uniek ID (1, 2 of 3), een geconfigureerd taalmodel en een temperatuurparameter. De klasse biedt twee centrale methoden: `respond()` voor de initiële inferentie en `challenge()` voor de adversariale kruisverificatie.

- `id`: int — uniek agent-ID (1..3).
- `model`: string — gekozen LLM (bijv. `claude-3-5-sonnet`, `gpt-4o`).
- `temperature`: float — sampling-temperatuur (0.65 / 0.70 / 0.75).
- `respond(prompt)`: AgentResponse — genereert een initiële respons op de prompt.
- `challenge(response)`: AgentResponse — genereert een adversariale verificatierespons.
- `score(response)`: ScoreResult — delegeert scoring aan de ScoringEngine.

Klasse: ScoringEngine

De ScoringEngine berekent de vertrouwensscore $S(R)$ voor een gegeven agentrespons. De vier gewichten (`alpha`, `beta`, `gamma`, `delta`) zijn configureerbaar per domein. De methode `calculate()` retourneert een ScoreResult-object met zowel de totaalscore als de vier deelscores.

- `alpha (a)`: float — gewicht voor interne consistentie $C(R)$. Standaard: 0.30.
- `beta (b)`: float — gewicht voor factual density $F(R)$. Standaard: 0.30.
- `gamma (g)`: float — gewicht voor semantische coherentie $Coh(R)$. Standaard: 0.25.
- `delta (d)`: float — gewicht voor bronverankering $Src(R)$. Standaard: 0.15.
- `calculate(R, P)`: ScoreResult — berekent de gewogen totaalscore.
- `measureConsistency(R)`: float — deelberekening voor $C(R)$.
- `measureFactuality(R)`: float — deelberekening voor $F(R)$.

Klasse: Harmonizer

De Harmonizer is verantwoordelijk voor het berekenen van divergentie en het integreren van de beste responscomponenten. De `divergence()`-methode berekent de cosinus-afstand (of Jaccard-afstand als proxy) tussen twee responsen. De `merge()`-methode bouwt een geconsolideerde respons op uit de consensus-zinnen.

- `divergence(a, b)`: float — berekent de semantische afstand tussen twee responsen.
- `merge(responses, scores)`: string — integreert superieure componenten tot geconsolideerde respons.
- `extractConsensus()`: string[] — extraheert zinnen met overlap in twee of meer agentresponsen.
- `computeJaccard(a, b)`: float — berekent Jaccard-overeenkomst als vereenvoudigde similariteitsmaatstaf.

Klasse: AgentResponse

AgentResponse is een data-object dat de uitkomst van een agentinferentie of challengerespons vastlegt. Het bevat de ruwe tekst, de berekende score, de deelscores en een markering of deze agent de winnaar is. AgentResponse heeft geen eigen gedrag (methoden) en is een zuiver informatiedrager.

- agentId: int — verwijzing naar de producerende agent.
- text: string — de volledige gegenereerde respons.
- score: float — de berekende vertrouwensscore $S(R)$.
- scoreBreakdown: ScoreResult — de deelscores per dimensie.
- isWinner: bool — true als deze respons de hoogste score heeft.

Klasse: NHMResult

NHMResult is het eindresultaat dat door de Orchestrator wordt geretourneerd aan de aanroepende applicatie. Het bevat de geharmoniseerde respons, metadata over het convergentieproces en auditinformatie.

- result: string — de geharmoniseerde eindrespons.
- confidence: float — de finale vertrouwensscore van de geconsolideerde respons.
- iterations: int — het aantal doorlopen iteratiecycli.
- converged: bool — true als het convergentiecriterium bereikt is.
- divergenceTrace: float[] — de $D(n)$ -waarden per iteratie.
- processingMs: int — de totale verwerkingstijd in milliseconden.

Relaties in het ontologie-model

Orchestrator 1 — uses — Agent 1..3 (afhankelijkheid)

De Orchestrator is afhankelijk van de Agent-klasse: hij instantieert en beheert drie Agent-objecten. De cardinaliteitsnotatie '1 — 1..3' duidt op een verplichte relatie waarbij de Orchestrator altijd ten minste één en standaard drie agents aanstuurt.

Orchestrator — uses — ScoringEngine (afhankelijkheid)

De Orchestrator delegeert de scoreberekening aan de ScoringEngine. Dit is een one-to-one afhankelijkheidsrelatie: de Orchestrator houdt één instantie van de ScoringEngine bij voor alle agentscorings.

Orchestrator — uses — Harmonizer (afhankelijkheid)

De Orchestrator roept de Harmonizer aan om divergentie te berekenen en de harmonisatieronden uit te voeren. Ook dit is een one-to-one relatie.

Agent — produces — AgentResponse (associatie)

Elke aanroep van `respond()` of `challenge()` op een Agent-object produceert een AgentResponse-instantie. Dit is een navigeerbare associatie van Agent naar AgentResponse, aangeduid met een volle pijl.

ScoringEngine — scores — AgentResponse (afhankelijkheid)

De ScoringEngine annoteert elke AgentResponse met een score. Deze gestippelde relatie geeft aan dat de ScoringEngine leest uit de AgentResponse maar er geen eigenaar van is.

AgentResponse — consolideert naar — NHMResult (afhankelijkheid)

Via de Harmonizer worden de drie AgentResponse-objecten samengevoegd tot een NHMResult. De gestippelde horizontale pijl in het diagram illustreert deze consolidatiestroom.

Harmonizer — produces — NHMResult (associatie)

De Harmonizer produceert het definitieve NHMResult-object. Dit is de enige klasse die verantwoordelijk is voor het aanmaken van het NHMResult.